

$$1. (1) L(p) = \prod_{k=1}^n P(X_k = x_k) = p^n (1-p)^{\sum_{k=1}^n x_k - n}$$

$$(2) \ln L(p) = n \ln p + (\sum_{k=1}^n x_k - n) \ln(1-p)$$

$$\frac{\partial \ln L(p)}{\partial p} = \frac{n}{p} - \frac{\sum_{k=1}^n x_k - n}{1-p} = 0 \Rightarrow \text{ML估计: } \hat{p} = \frac{n}{\sum_{k=1}^n x_k}$$

$$(3) E(X) = \frac{1}{p} = a_1 = \frac{1}{n} \sum_{k=1}^n x_k \Rightarrow \text{-阶矩估计: } \hat{p} = \frac{n}{\sum_{k=1}^n x_k}$$

$$2. L(\mu, \sigma) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_k - \mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{1}{2\sigma^2}(\sum_{k=1}^n x_k^2 - 2\mu \sum_{k=1}^n x_k + n\mu^2)}$$

$$\ln L(\mu, \sigma) = -n \ln \sqrt{2\pi} - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{k=1}^n x_k^2 + \frac{\mu}{\sigma^2} \sum_{k=1}^n x_k - \frac{n\mu^2}{2\sigma^2}$$

$$(1) \frac{\partial \ln L(\mu, \sigma)}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{k=1}^n x_k^2 - \frac{2\mu}{\sigma^3} \sum_{k=1}^n x_k + \frac{n\mu^2}{\sigma^3}$$

$$\hat{\sigma} \frac{\partial \ln L(\mu, \sigma)}{\partial \sigma} = 0 \text{ 得 } \hat{\sigma}^2 = \mu^2 - 2\mu \cdot \frac{1}{n} \sum_{k=1}^n x_k + \frac{1}{n} \sum_{k=1}^n x_k^2$$

$$(2) \frac{\partial \ln L(\mu, \sigma)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{k=1}^n x_k - \frac{n\mu}{\sigma^2} \hat{\mu} = \frac{\partial \ln L(\mu, \hat{\sigma})}{\partial \mu} = 0 \text{ 得 } \hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k$$

$$3. L(\theta) = \prod_{k=1}^n p(x_k, \theta) = e^{n\theta - \sum_{k=1}^n x_k} I_{\{x_1, \dots, x_n \geq \theta\}}$$

$$\text{当 } \theta \leq \min\{x_1, \dots, x_n\} \text{ 时 } \frac{\partial L(\theta)}{\partial \theta} = n e^{n\theta - \sum_{k=1}^n x_k} > 0$$

当 $\theta > \min\{x_1, \dots, x_n\}$ 时 $L(\theta) = 0$, 不会得到 ML 估计

由此可见, $\theta = \min\{x_1, \dots, x_n\}$ 时 $L(\theta)$ 取到最大值. 故 $T_1 = \min\{x_1, \dots, x_n\}$

$$4. (1) \text{var}(X_1) = E(X_1^2) - (E(X_1))^2 = p(1-p)$$

(2) 先求 p 的 ML 估计. $L(p) = \prod_{k=1}^n P(x_k = x_k) = p^{\sum_{k=1}^n x_k} (1-p)^{n - \sum_{k=1}^n x_k}$

$$\ln L(p) = \left(\sum_{k=1}^n x_k \right) \ln p + \left(n - \sum_{k=1}^n x_k \right) \ln(1-p)$$

$$\frac{\partial \ln L(p)}{\partial p} = \frac{\sum_{k=1}^n x_k}{p} - \frac{n - \sum_{k=1}^n x_k}{1-p} \quad \text{令 } \frac{\partial \ln L(p)}{\partial p} = 0 \text{ 得 } \hat{p} = \frac{1}{n} \sum_{k=1}^n x_k$$

于是 $\text{var}(x_i) = p(1-p)$ 的 ML 估计为 $T = \hat{p}(1-\hat{p})$

$$\begin{aligned} (3) \quad E\left(T(x_1, \dots, x_n)\right) &= E\left(\frac{1}{n} \sum_{k=1}^n x_k - \frac{1}{n^2} \left(\sum_{k=1}^n x_k\right)^2\right) = \frac{1}{n} \sum_{k=1}^n E(x_k) - \frac{1}{n^2} \sum_{k=1}^n E(x_k^2) - \frac{2}{n^2} \sum_{1 \leq i < j \leq n} E(x_i x_j) \\ &= \frac{1}{n} \cdot n \cdot p - \frac{1}{n^2} \cdot n \cdot p - \frac{2}{n^2} \cdot \frac{1}{2} n(n-1) \cdot p^2 = \frac{n-1}{n} p(1-p) \end{aligned}$$

5. (1) $\text{var}(\hat{p}) = \text{var}\left(\frac{S}{n}\right) = \frac{1}{n^2} \cdot np(1-p) = \frac{1}{n} p(1-p)$

(2) $\text{var}(\hat{p}) = \frac{1}{n} p(1-p)$ 的 ML 估计为 $\frac{1}{n} \hat{p}(1-\hat{p}) = \frac{S(n-S)}{n^3}$

6. (1) $E(x) = \int_0^{+\infty} x e^{\theta-x} dx = - \int_0^{+\infty} x d(e^{\theta-x}) = -x e^{\theta-x} \Big|_0^{+\infty} + \int_0^{+\infty} e^{\theta-x} dx = 1 + \theta$
 $= a_1 = \frac{1}{n} \sum_{k=1}^n x_k$. 则 -1 阶矩估计为 $\hat{\theta} = \frac{1}{n} \sum_{k=1}^n x_k - 1$

(2) 设 $Y = T_1 - \theta = \min\{x_1 - \theta, \dots, x_n - \theta\}$. 注意 $x_k - \theta$ 的分布密度为 $\begin{cases} e^{-x} & x \geq 0 \\ 0 & x < 0 \end{cases}$

则 $y \geq 0$ 时 $P(Y \leq y) = 1 - P(Y > y) = 1 - P(x_1 - \theta > y) \cdots P(x_n - \theta > y) = 1 - e^{-ny}$

因此 Y 的分布密度 $P_Y(y) = \begin{cases} ne^{-ny} & \text{当 } y \geq 0 \text{ 时} \\ 0 & \text{当 } y < 0 \text{ 时} \end{cases}$

$$E_{\theta}((T_1 - \theta)^2) = E(Y^2) = \int_0^{+\infty} y^2 \cdot ne^{-ny} dy = - \int_0^{+\infty} y^2 d(e^{-ny})$$

$$= -y^2 e^{-ny} \Big|_0^{+\infty} + 2 \int_0^{+\infty} y e^{-ny} dy = -\frac{2}{n} \int_0^{+\infty} y d(e^{-ny})$$

$$= -\frac{2}{n} y e^{-ny} \Big|_0^{+\infty} + \frac{2}{n} \int_0^{+\infty} e^{-ny} dy = \frac{2}{n^2}$$

$$E_{\theta}((T_2 - \theta)^2) = \text{var}(T_2 - \theta) + (E(T_2 - \theta))^2$$

$$E(T_2) = \frac{1}{n} \sum_{k=1}^n E(X_k) - 1 = \theta \Rightarrow E(T_2 - \theta) = 0$$

$$\begin{aligned} \text{var}(T_2 - \theta) &= \text{var}(T_2) = \text{var}\left(\frac{1}{n} \sum_{k=1}^n X_k - 1\right) = \frac{1}{n^2} \sum_{k=1}^n \text{var}(X_k) \\ &= \frac{1}{n^2} \cdot n \cdot \int_0^{+\infty} (x - \theta - 1) e^{\theta - x} dx = \frac{1}{n} \end{aligned}$$

7. (2) 设 $Y = \max_{1 \leq i \leq n} \{X_i\}$. 则 $0 \leq y \leq \theta$ 时 $P(Y \leq y) = P(X_1 \leq y) \cdots P(X_n \leq y) = \left(\frac{y}{\theta}\right)^n$

于是 $P_Y(y) = \begin{cases} \frac{1}{\theta^n} \cdot n y^{n-1}, & \text{当 } 0 \leq y \leq \theta \text{ 时} \\ 0, & \text{其它} \end{cases}$

$$(1) E_{\theta}(\hat{\theta}) = \int_0^{\theta} y \cdot \frac{1}{\theta^n} \cdot n y^{n-1} dy = \frac{n}{n+1} \theta$$

8. (1) $E(X) = \int_0^1 x \cdot \theta x^{\theta-1} dx = \frac{\theta}{\theta+1} = \frac{1}{n} \sum_{k=1}^n X_k$. 则 $\hat{\theta} = \frac{\sum_{k=1}^n X_k}{n - \sum_{k=1}^n X_k}$

$$(2) L(\theta) = \prod_{k=1}^n p(X_k, \theta) = \theta^n x_1^{\theta-1} \cdots x_n^{\theta-1} \quad \ln L(\theta) = n \ln \theta + (\theta-1) \sum_{k=1}^n \ln x_k$$

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{n}{\theta} + \sum_{k=1}^n \ln x_k. \quad \text{则 } \hat{\theta} = - \frac{n}{\sum_{k=1}^n \ln x_k}$$

9. $L(\mu, \sigma) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_k - \mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{1}{2\sigma^2} \left(\sum_{k=1}^n x_k^2 - 2\mu \sum_{k=1}^n x_k + n\mu^2\right)}$

$$\ln L(\mu, \sigma) = -n \ln \sqrt{2\pi} - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{k=1}^n x_k^2 + \frac{\mu}{\sigma^2} \sum_{k=1}^n x_k - \frac{n\mu^2}{2\sigma^2}$$

$$\begin{cases} \frac{\partial \ln L(\mu, \sigma)}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{k=1}^n x_k^2 - \frac{2\mu}{\sigma^3} \sum_{k=1}^n x_k + \frac{n\mu^2}{\sigma^3} = 0 \\ \frac{\partial \ln L(\mu, \sigma)}{\partial \mu} = \frac{1}{\sigma^2} \sum_{k=1}^n x_k - \frac{n\mu}{\sigma^2} = 0 \end{cases}$$

$$\Rightarrow \hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k, \quad \hat{\sigma}^2 = \mu^2 - 2\mu \cdot \frac{1}{n} \sum_{k=1}^n x_k + \frac{1}{n} \sum_{k=1}^n x_k^2 = \frac{1}{n} \sum_{k=1}^n x_k^2 - \frac{1}{n^2} \left(\sum_{k=1}^n x_k\right)^2$$

10. 回顾 $\chi^2(n)$ 分布的定义:

随机变量 $Z_1, \dots, Z_n$ 相互独立, 且都服从 $N(0, 1)$.

那么 $\eta = Z_1^2 + \dots + Z_n^2$ 服从自由度为 n 的卡方分布, 记作 $\eta \sim \chi^2(n)$

$$\text{概率密度 } f_\eta(x) = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} \quad (x > 0)$$

$$\text{现在已知 } f_z(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}}, \quad f_\eta(v) = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} v^{\frac{n}{2}-1} e^{-\frac{v}{2}} \quad (v > 0)$$

目标是要计算 $X = \frac{z}{\sqrt{\eta/n}}$ 的概率密度.

$$\text{由 } z \text{ 与 } \eta \text{ 独立知 } f_{z,\eta}(u,v) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} \cdot \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} v^{\frac{n}{2}-1} e^{-\frac{v}{2}}$$

$$\text{令 } \begin{cases} X = \frac{z}{\sqrt{\eta/n}} \\ Y = \eta \end{cases} \text{ 即 } \begin{cases} z = \frac{\sqrt{Y}}{\sqrt{n}} X \\ \eta = Y \end{cases}$$

用一维来理解: $P(x \leq X \leq x+dx) = P(y \leq Y \leq y+dy)$

$$\text{则 } f_{X,Y}(x,y) = f_{z,\eta}(z,\eta) \cdot \left| \frac{\partial(z,\eta)}{\partial(x,y)} \right| \quad \Rightarrow f_X(x) dx = f_Y(y) dy$$

$$= \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \cdot \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} \eta^{\frac{n}{2}-1} e^{-\frac{\eta}{2}} \cdot \begin{vmatrix} \frac{\sqrt{y}}{\sqrt{n}} & \frac{x}{\sqrt{n}} \cdot \frac{1}{2\sqrt{y}} \\ 0 & 1 \end{vmatrix} \quad \Rightarrow f_X(x) \frac{dx}{dy} = f_Y(y)$$

$$= \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2 y}{2n}} \cdot \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} y^{\frac{n}{2}-1} e^{-\frac{y}{2}} \cdot \frac{y^{\frac{1}{2}}}{\sqrt{n}} \quad (\text{注意 } \eta \text{ 只取 } > 0 \text{ 的值, 所以 } Y \text{ 也是})$$

$$\text{于是 } f_X(x) = \int_0^{+\infty} \frac{1}{\sqrt{2\pi}} \cdot \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} \cdot \frac{1}{\sqrt{n}} \cdot e^{-(\frac{x^2}{2n} + \frac{1}{2})y} y^{\frac{n-1}{2}} dy$$

$$\text{利用 Gamma 函数的定义: } \int_0^{+\infty} x^{\alpha-1} e^{-\beta x} dx = \frac{\Gamma(\alpha)}{\beta^\alpha}$$

$$\text{这里 } \alpha = \frac{n+1}{2}, \quad \beta = \frac{1}{2} \left(1 + \frac{x^2}{n} \right). \text{ 代入上式得}$$

$$f_X(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n} \right)^{-\frac{n+1}{2}} \quad (x \in \mathbb{R}). \text{ 这正是 } t(n) \text{ 分布的定义.}$$

11. 要证明 $T = \sum_{i=1}^n X_i$ 为充分统计量, 就是要证

$\forall t, i_1, \dots, i_n \in \mathbb{N}^*, i_1 + \dots + i_n = t$, 有: $P(X_1 = i_1, \dots, X_n = i_n | T = t)$ 与 λ 无关.

这题有个关键结论, 就是说如果 $X \sim \text{Poisson}(\lambda_1)$,

$Y \sim \text{Poisson}(\lambda_2)$, 且 X 与 Y 独立, 则 $X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2)$

先证一下这个结论. $P(X + Y = n) = \sum_{k=0}^n P(X = k) P(Y = n - k)$

$$= \sum_{k=0}^n \frac{\lambda_1^k}{k!} e^{-\lambda_1} \cdot \frac{\lambda_2^{n-k}}{(n-k)!} e^{-\lambda_2} = \frac{\lambda_1^n}{n!} e^{-\lambda_1 - \lambda_2} \sum_{k=0}^n \frac{n!}{k!(n-k)!} \left(\frac{\lambda_1}{\lambda_2}\right)^k = \frac{(\lambda_1 + \lambda_2)^n}{n!} e^{-\lambda_1 - \lambda_2}$$

回原题. 这样我们就知道 $T \sim \text{Poisson}(n\lambda)$

$$\text{于是 } P(X_1 = i_1, \dots, X_n = i_n | T = t) = \frac{P(X_1 = i_1, \dots, X_n = i_n, T = t)}{P(T = t)}$$

$$= \frac{\prod_{k=1}^n \frac{\lambda^{i_k}}{i_k!} e^{-\lambda}}{\frac{(n\lambda)^t}{t!} e^{-n\lambda}} = \frac{t!}{i_1! \dots i_n!} \cdot \frac{1}{n^t}. \text{ 可以看出确实与 } \lambda \text{ 无关}$$

12. $\frac{\sigma}{\mu}$ 的 ML 估计就等于 $\frac{\hat{\sigma}}{\hat{\mu}}$. 其中 $\hat{\sigma}$ 和 $\hat{\mu}$ 是 σ 和 μ 分别的 ML 估计

$$L(\mu, \sigma) = \prod_{k=1}^n P(X = x_k) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_k - \mu)^2}{2\sigma^2}}$$

$$\begin{aligned} \ln L(\mu, \sigma) &= \sum_{k=1}^n \left(-\ln(\sqrt{2\pi}) - \ln\sigma - \frac{(x_k - \mu)^2}{2\sigma^2} \right) \rightarrow \sum_{k=1}^n [(x_k - \bar{x}) + (\bar{x} - \mu)]^2 \\ &= \sum_{k=1}^n (x_k - \bar{x})^2 + (\bar{x} - \mu) \sum_{k=1}^n (x_k - \bar{x}) + n(\bar{x} - \mu)^2 \\ &= -n \ln(\sqrt{2\pi}) - n \ln\sigma - \frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2 = \sum_{k=1}^n (x_k - \bar{x})^2 + n(\bar{x} - \mu)^2 \end{aligned}$$

$$= -n \ln(\sqrt{2\pi}) - n \ln\sigma - \frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \bar{x})^2 - \frac{n}{2\sigma^2} (\bar{x} - \mu)^2$$

$$\frac{\partial \ln L(\mu, \sigma)}{\partial \mu} = -\frac{n}{\sigma^2}(\mu - \bar{x}) \quad \text{所以 } \mu < \bar{x} \text{ 时 } L \uparrow, \mu \geq \bar{x} \text{ 时 } L \downarrow$$

这也就是说, $\hat{\mu} = \begin{cases} \bar{x}, & \text{当 } \bar{x} \geq 0 \text{ 时} \\ 0, & \text{当 } \bar{x} < 0 \text{ 时} \end{cases}$

$$\frac{\partial \ln L(\mu, \sigma)}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{k=1}^n (x_k - \mu)^2 = \frac{n}{\sigma^3} \left[\frac{1}{n} \sum_{k=1}^n (x_k - \mu)^2 - \sigma^2 \right]$$

所以 $0 < \sigma < \sqrt{\frac{1}{n} \sum_{k=1}^n (x_k - \mu)^2}$ 时 $L \uparrow$, $\sigma \geq \sqrt{\frac{1}{n} \sum_{k=1}^n (x_k - \mu)^2}$ 时 $L \downarrow$

这也就是说, $\hat{\sigma} = \begin{cases} \sqrt{\frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2}, & \text{当 } \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2 \leq 2 \text{ 时} \\ \sqrt{2}, & \text{当 } \frac{1}{n} \sum_{k=1}^n (x_k - \hat{\mu})^2 > 2 \text{ 时} \end{cases}$

综上所述, $\frac{\sigma}{\mu}$ 的 ML 估计为 $\frac{\sqrt{\min(\frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2, 2)}}{\bar{x}}$

$$13. \prod_{i=1}^n p(x_i, y_i, \theta) = \left(\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \right)^n \exp \left\{ -\frac{1}{2(1-\rho^2)} \sum_{i=1}^n \left[\left(\frac{x_i - \mu_1}{\sigma_1} \right)^2 - \frac{2\rho(x_i - \mu_1)(y_i - \mu_2)}{\sigma_1\sigma_2} + \left(\frac{y_i - \mu_2}{\sigma_2} \right)^2 \right] \right\}$$

而 $\sum_{i=1}^n \left(\frac{x_i - \mu_1}{\sigma_1} \right)^2 = \sum_{i=1}^n \left(\frac{(x_i - \bar{x}) + (\bar{x} - \mu_1)}{\sigma_1} \right)^2 = \frac{1}{\sigma_1^2} \left[\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu_1)^2 \right]$

$$\sum_{i=1}^n \left(\frac{y_i - \mu_2}{\sigma_2} \right)^2 = \sum_{i=1}^n \left(\frac{(y_i - \bar{y}) + (\bar{y} - \mu_2)}{\sigma_2} \right)^2 = \frac{1}{\sigma_2^2} \left[\sum_{i=1}^n (y_i - \bar{y})^2 + n(\bar{y} - \mu_2)^2 \right]$$

$$\sum_{i=1}^n \frac{2\rho(x_i - \mu_1)(y_i - \mu_2)}{\sigma_1\sigma_2} = \frac{2\rho}{\sigma_1\sigma_2} \sum_{i=1}^n \left[(x_i - \bar{x} + \bar{x} - \mu_1)(y_i - \bar{y} + \bar{y} - \mu_2) \right]$$

$$= \frac{2\rho}{\sigma_1\sigma_2} \left[\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) + \underbrace{(\bar{x} - \mu_1) \sum_{i=1}^n (y_i - \bar{y})}_{=0} + \underbrace{(\bar{y} - \mu_2) \sum_{i=1}^n (x_i - \bar{x})}_{=0} + n(\bar{x} - \mu_1)(\bar{y} - \mu_2) \right]$$

$$= \frac{2\rho}{\sigma_1\sigma_2} \left(\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) + n(\bar{x} - \mu_1)(\bar{y} - \mu_2) \right)$$

14. (1) 由于 $E_0(x) = n\theta$. 所以 $\hat{\theta} = \frac{x}{n}$ 是无偏估计

再求 $\theta(1-\theta)$ 的无偏估计. 也就是要找 $E_0[\text{某个东西}] = \theta(1-\theta)$

那什么东西的期望会出 θ^2 呢? 应该是 $E_{\theta}(X^2) = \text{var}_{\theta}(X) + (E_{\theta}(X))^2 = n\theta(1-\theta) + (n\theta)^2$

所以就是 $E_{\theta}(aX^2 + bX + c) = \theta(1-\theta)$. 解方程知 $a = -\frac{1}{n(n-1)}$, $b = \frac{1}{n-1}$, $c = 0$

$$\text{即 } \hat{\theta}(1-\hat{\theta}) = -\frac{1}{n(n-1)}X^2 + \frac{1}{n-1}X$$

$$(2) \hat{\theta} \text{ 的均方误差} = E_{\theta}((\hat{\theta} - \theta)^2) = E_{\theta}\left(\left(\frac{X}{n} - \theta\right)^2\right)$$

$$= E_{\theta}\left(\left(\frac{X}{n} - \theta\right)^2\right) - \left(E_{\theta}\left(\frac{X}{n} - \theta\right)\right)^2 = \text{var}_{\theta}\left(\frac{X}{n} - \theta\right) = \text{var}_{\theta}\left(\frac{X}{n}\right) = \frac{1}{n}\theta(1-\theta)$$

(其实结论是, 如果 $\hat{\theta}$ 是无偏估计, 那 $\hat{\theta}$ 的均方误差就是方差)

$$15. (1) E(n_1) = n\theta^2, E(n_2) = 2n\theta(1-\theta). \text{ 因此 } E(\hat{\theta}_n) = \frac{1}{n}E(n_1) + \frac{1}{2n}E(n_2) = \theta$$

(2) $\hat{\theta}_n$ 是无偏估计, 因此均方误差为方差, 即为

$$\begin{aligned} \text{var}_{\theta}(\hat{\theta}_n) &= \text{var}_{\theta}\left(\frac{2n_1 + n_2}{2n}\right) = \frac{1}{4n^2} E_{\theta}\left[\left(2(n_1 - E(n_1)) + (n_2 - E(n_2))\right)^2\right] \\ &= \frac{1}{4n^2} \left[4E_{\theta}\left((n_1 - E(n_1))^2\right) + 4E_{\theta}\left((n_1 - E(n_1))(n_2 - E(n_2))\right) + E_{\theta}\left((n_2 - E(n_2))^2\right) \right] \end{aligned}$$

$$\text{而 } E\left((n_1 - E(n_1))(n_2 - E(n_2))\right) = E(n_1 n_2) - E(n_1)E(n_2)$$

$$E(n_1 n_2) = \sum_{n_1=0}^n \sum_{n_2=0}^{n-n_1} n_1 n_2 \cdot C_n^{n_1} p_1^{n_1} C_{n-n_1}^{n_2} p_2^{n_2} (1-p_1-p_2)^{n-n_1-n_2}$$

可以猛算出上面的求和, 但我们这里给出一个优雅解法

我们先定义 $2n$ 个变量: $I_t^{(1)} = \begin{cases} 1, & \text{如果第 } t \text{ 个个体为种类 1} \\ 0, & \text{其它} \end{cases}$ $I_t^{(2)} = \begin{cases} 1, & \text{如... 为种类 2} \\ 0, & \text{其它} \end{cases}$

$$\text{那么 } n_1 = \sum_{t=1}^n I_t^{(1)}, n_2 = \sum_{t=1}^n I_t^{(2)}. \text{ 于是 } \text{Cov}(n_1, n_2) = E\left((n_1 - E(n_1))(n_2 - E(n_2))\right)$$

$$= E\left(\left(\sum_{i=1}^n (I_i^{(1)} - E(I_i^{(1)}))\right)\left(\sum_{j=1}^n (I_j^{(2)} - E(I_j^{(2)}))\right)\right) = \sum_{i=1}^n \sum_{j=1}^n E\left((I_i^{(1)} - E(I_i^{(1)}))(I_j^{(2)} - E(I_j^{(2)}))\right)$$

$$\text{对于 } i \neq j, I_i^{(1)} \text{ 与 } I_j^{(2)} \text{ 独立, 此时 } E\left((I_i^{(1)} - E(I_i^{(1)}))(I_j^{(2)} - E(I_j^{(2)}))\right) = 0$$

对于 $i=j$, 由于 $I_i^{(1)}$ 与 $I_j^{(1)}$ 至少有一个为 0, 则 $E(I_i^{(1)} I_j^{(1)}) = 0$

$$\text{此时 } E((I_i^{(1)} - E(I_i^{(1)}))(I_j^{(1)} - E(I_j^{(1)}))) = E(I_i^{(1)} I_j^{(1)}) - E(I_i^{(1)}) E(I_j^{(1)}) = -p_1 p_2$$

$$\text{所以 } E((n_1 - E(n_1))(n_2 - E(n_2))) = -np_1 p_2$$

$$\begin{aligned} \text{代回原式得 } \text{var}_\theta(\hat{\theta}_n) &= \frac{1}{4n^2} \left[4 \cdot n\theta^2(1-\theta^2) + 4 \cdot (-n\theta^2 \cdot 2\theta(1-\theta)) + n(1-\theta)^2(1-(1-\theta)^2) \right] \\ &= \frac{1}{4n} (3\theta^4 - 4\theta^3 - \theta^2 + 2\theta) = \frac{1}{4n} \theta(\theta-1)^2(3\theta+2) \end{aligned}$$

先梳理一下本书范围内如何找 UMVU 估计:

定义 1: 待估量 $g(\theta)$, 统计量 T . 如果满足 (1) T 是 $g(\theta)$ 的无偏估计 (2) 对于 $g(\theta)$ 的任何其它无偏估计 $\tilde{T}$, 有 $\text{var}_\theta(T) \leq \text{var}_\theta(\tilde{T})$ ($\forall \theta \in \Theta$)
则称 T 为 $g(\theta)$ 的最小方差无偏估计 (UMVU 估计)

理解 1: 我们评估一个估计 T 的好坏, 直观上来说就是看 $[T - g(\theta)]^2$, 或者说就是看 $E_\theta[(T - g(\theta))^2]$, 它越小就代表估计越好. 那是否存在一个 T^* 使得对任意的 θ , $E_\theta[(T^* - g(\theta))^2] \leq E_\theta[(\tilde{T} - g(\theta))^2]$ ($\forall \tilde{T}$) 呢? 不行. 因为 $\theta = \theta_0$ 时, 取 $\tilde{T} = g(\theta_0)$, 则 $E_\theta[(\tilde{T} - g(\theta))^2] \big|_{\theta=\theta_0} = 0$. 那这就要求 $T^* = g(\theta)$ 几乎处处成立. 所以我们退而求其次, 在无偏估计类中找使得 $E_\theta[(T - g(\theta))^2]$ 处处最小的 T . 此时就有可能找到了. 由于是无偏估计, 所以 $E_\theta[(T - g(\theta))^2] = \text{var}(T)$. 因此取名叫最小方差无偏估计

理解 2: 想要找无偏估计本身就很难, 想证明其中某个估计处处方差最小更加绝非易事, 所以用定义来求 UMVU 估计基本不在本书考虑范围之内. 本书中求

UMVU估计的方法需要引入充分统计量的概念

定义2: 设 $(x_1, \dots, x_n) \sim F_\theta(x_1, \dots, x_n)$. 对于一个统计量 $T(x_1, \dots, x_n)$, 如果在 T 已知的情况下, 其它任何统计量 $\tilde{T}$ 的条件分布与参数 θ 无关, 则称 T 为充分统计量.

理解3: 充分统计量意思就是已经包含了参数 θ 的所有信息. 用定义验证的方法就是去算 $P(x_1=x_1, \dots, x_n=x_n | T=T(x_1, \dots, x_n))$ 这个条件概率, 然后证明表达式中不含 θ . 不过也有现成定理可以用. 如下

定理1: (Fisher-Neyman因子分解定理) 设 $x_1, \dots, x_n \sim \text{iid } p(x, \theta)$. 若 $\prod_{i=1}^n p(x_i, \theta)$ 可以写成 $g_\theta(T(x_1, \dots, x_n))h(x_1, \dots, x_n)$ 的形式, 其中 h 与 θ 无关, $g_\theta(T)$ 表示它是关于 T 的函数. 则 T 为充分统计量

定义3: 设 $x_1, \dots, x_n \sim \text{iid } p(x, \theta)$, T 是充分统计量. 如果对任意满足

$E_\theta[\varphi(T(x_1, \dots, x_n))] \equiv 0 \ (\forall \theta \in \Theta)$ 的统计量, 有 $P_\theta(\varphi(T(x_1, \dots, x_n)) = 0) = 1 \ (\forall \theta \in \Theta)$.

则称 T 为完全充分统计量

理解4: 为什么要提出「完全」充分统计量呢? 因为我们发现充分统计量之间亦有差别. 比如 n 维向量 $(x_1, \dots, x_n)$ 就是一个平凡的充分统计量, 但是没啥用. 我们说充分统计量包含了 θ 的所有信息, 实际上是想用最少的信息去复原 θ 的信息.

理解5: 完全充分统计量是说我现在有一个充分统计量 T , 我不可能利用 T 去构造出一个统计量是 0 的无偏估计了 (类似于说, 如果能用 T 的一些部分组合出 0 , 那这些部分就有多余的. 可能可以类比向量组线性相关). 换句话说, 依赖于 T 的 $g(\theta)$ 的无偏估计最多只有一个 (如果有两个, 减 T 就是 0 的无偏估计)

定理2: 设 $X_1, \dots, X_n \sim \text{iid } p(x, \theta)$. T 为完全充分统计量. 若 $\varphi(T)$ 满足

$$E_{\theta}(\varphi(T)) = g(\theta) \quad (\forall \theta \in \Theta). \text{ 则 } \varphi(T) \text{ 为 } g(\theta) \text{ 的 UMVU 估计}$$

理解6: 所以上面绕了这么大一圈, 总结就是, 要找 $g(\theta)$ 的 UMVU 估计, 只需先

找完全充分统计量 T , 然后在 T 的函数中去找无偏估计就行. 但是我们

发现完全充分统计量还是很难求. 下面的定理给出了特殊情况下的求法

定义4: 如果 $p(x, \theta)$ 能写成 $S(\theta)h(x)\exp\{\sum_{k=1}^m C_k(\theta)T_k(x)\}$ 的形式, 则称 $p(x, \theta)$ 为指数族分布

定理3: 设 X 的分布密度为 $p(x, \theta) = S(\theta)h(x)\exp\{\sum_{k=1}^m C_k(\theta)T_k(x)\}$. 那么在比较好的性质下, 对于来自总体 X 的样本 $X = (X_1, \dots, X_n)$, $(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_m(X_i))$ 是该

统计模型的完全充分统计量. (“比较好的性质”指: Θ 是 m 维空间中含有

内点的集合, $\theta \rightarrow (C_1(\theta), \dots, C_m(\theta))$ 是一一对应的连续函数, $C_1 \sim C_m$ 线性无关,

$T_1 \sim T_m$ 线性无关)

总结一下: 题目让你求 $g(\theta)$ 的 UMVU 估计, 一般套路就是

① 证明 X 具有指数族分布, 且性质较好

↓ 定理3

② 得出完全充分统计量 T . 根据 $E(T)$ 的形式猜 $E(f(T)) = g(\theta)$ 的 f 是什么

↓ 定理2

③ 这个满足 $E(f(T)) = g(\theta)$ 的 $f(T)$ 就是所求的 UMVU 估计

$$16. (1) \quad p(x, \mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2}} = \underbrace{\frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}}_{h(x)} \cdot \underbrace{e^{-\frac{\mu^2}{2}}}_{S(\mu)} \cdot \underbrace{\exp\{\mu \cdot x\}}_{\sum_{i=1}^m C_i(\mu) T_i(x)}$$

而 μ 的取值范围含内点, $\mu \rightarrow C_1(\mu)$ 是连续的一一映射. $C_1(\mu)$ 线性无关, $T_1(x)$ 线性无关

因此 $T = X_1 + \dots + X_n$ 是完全充分统计量

而 $E(T) = n\mu$. 因此 $E(\frac{T}{n}) = \mu$. 故 $\frac{T}{n}$ 是无偏估计, 进而有 $\frac{T}{n}$ 是 μ 的 UMVU 估计

(2) 已有 $T = \sum_{i=1}^n X_i$ 是充分统计量. 要找 μ^2 的 UMVU 估计, 就是要找 $\varphi(T)$

使 $E(\varphi(T)) = \mu^2$, 这样 $\varphi(T)$ 就是 UMVU 估计

根据量级来说, $\varphi(T)$ 中应该包含 T^2 这一项.

先算一下 $E(T^2) = \text{var}(T) + (E(T))^2 = n + n^2\mu^2$ (因为 $T \sim N(n\mu, n)$)

因此 $E\left(\frac{1}{n^2}T^2 - \frac{1}{n}\right) = \mu^2$. 故 $\frac{1}{n^2}T^2 - \frac{1}{n}$ 是 μ^2 的 UMVU 估计

(3) $E(T^3) = E((T - n\mu)^3 + 3T^2(n\mu) - 3T(n\mu)^2 + (n\mu)^3) = 3n\mu E(T^2) - 3n\mu^2 E(T) + n^3\mu^3 = 3n^2\mu + n^3\mu^3$

因此 $E\left(\frac{1}{n^3}T^3 - \frac{3}{n}T\right) = \mu^3$. 故 $\frac{1}{n^3}T^3 - \frac{3}{n}T$ 是 μ^3 的 UMVU 估计

$$17. p(x, \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \underbrace{1}_{h(x)} \cdot \underbrace{\frac{1}{\sqrt{2\pi}\sigma}}_{S(\theta)} \cdot \underbrace{\exp\left\{-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x\right\}}_{\substack{C_1(\theta) T_1(x) \\ C_2(\theta) T_2(x)}}$$

包含内点 + 连续双射 + 线性无关 $\Rightarrow T_1 = \left(\sum_{i=1}^n X_i^2, \sum_{i=1}^n X_i\right)$ 是完全充分统计量

$T(X_1, \dots, X_n) = \bar{X}^2 - \frac{1}{n(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2 = \bar{X}^2 - \frac{1}{n(n-1)} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)$ 是 T_1 的函数

$$E(T(X_1, \dots, X_n)) = E\left(\frac{n}{n-1} \bar{X}^2 - \frac{1}{n(n-1)} \sum_{i=1}^n X_i^2\right) = \frac{n}{n-1} \left(\frac{\sigma^2}{n} + \mu^2\right) - \frac{1}{n(n-1)} n(\sigma^2 + \mu^2) = \mu^2$$

以上三行综合起来就能推出 T 是 μ^2 的 UMVU 估计了.

思考: 如果这题没给结果, 让你直接求 μ^2 的 UMVU 估计, 怎么办?

—— 得到 $(\sum_{i=1}^n X_i^2, \sum_{i=1}^n X_i)$ 是完全充分统计量后, 根据量级, 猜测 $E(\text{一堆 } X_i \text{ 的平方}) = \mu^2$

然后待定 A, B , 由 $E\left(A \sum_{i=1}^n X_i^2 + B \left(\sum_{i=1}^n X_i\right)^2\right) = \mu^2$ 把 A, B 解出来

$$18. E(\bar{X}) = \frac{1}{n} \cdot n E(X_1) = \lambda$$

$$E(X_1^2) = \sum_{k=0}^{+\infty} k^2 \cdot \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=1}^{+\infty} ((k^2 - k) + k) \cdot \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=2}^{+\infty} \frac{\lambda^k}{(k-2)!} e^{-\lambda} + \sum_{k=1}^{+\infty} \frac{\lambda^k}{(k-1)!} e^{-\lambda} = \lambda^2 + \lambda$$

$$E\left(\left(\sum_{i=1}^n X_i\right)^2\right) = n^2 \lambda^2 + n \lambda \quad (\text{我们在11题的解答中证明过了 } \sum_{i=1}^n X_i \sim \text{Poisson}(n\lambda))$$

$$E\left(\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2\right) = E\left(\frac{1}{n-1} \sum_{i=1}^n x_i^2 - \frac{n}{n-1} \bar{x}^2\right) = \frac{n}{n-1} E(x_i^2) - \frac{1}{n(n-1)} E\left(\left(\sum_{i=1}^n x_i\right)^2\right) = \lambda$$

19. 对任意 $(i_1, \dots, i_n)$ ($i_k \in \{0, 1\}$). 如果 $i_1 + \dots + i_n \neq t$, 则 $P(X_1=i_1, \dots, X_n=i_n | T=t) = 0$

$$\text{如果 } i_1 + \dots + i_n = t, \text{ 则 } P(X_1=i_1, \dots, X_n=i_n | T=t) = \frac{p^t (1-p)^{n-t}}{C_n^t p^t (1-p)^{n-t}} = \frac{1}{C_n^t}$$

也就是说 $T=t$ 的条件下 $(X_1, \dots, X_n)$ 的分布与 p 无关. 因此 $\tilde{T} = X_1 + X_2$ 的分布也与 p 无关

20. $(X_1, \dots, X_n)$ 的联合密度为 $\prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = (1-p)^n \exp\left\{\left(\sum_{i=1}^n x_i\right) \ln\left(\frac{p}{1-p}\right)\right\}$

$$S(p) = (1-p)^n, \quad h(x) = 1, \quad C_1(p) = \ln \frac{p}{1-p}, \quad T_1(x) = \sum_{i=1}^n x_i. \quad \text{因此是指数族分布}$$

进而可知 $T = \sum_{i=1}^n x_i$ 是这个统计模型的完全充分统计量

21. $(X_1, \dots, X_n)$ 的联合密度为 $\prod_{i=1}^n \theta(1-\theta)^{x_i-1} = \left(\frac{\theta}{1-\theta}\right)^n \exp\left\{\left(\sum_{i=1}^n x_i\right) \ln(1-\theta)\right\}$

$$S(\theta) = \left(\frac{\theta}{1-\theta}\right)^n, \quad h(x) = 1, \quad C_1(\theta) = \ln(1-\theta), \quad T_1(x) = \sum_{i=1}^n x_i. \quad \text{因此是指数族分布}$$

进而可知 $T = \sum_{i=1}^n x_i$ 是这个统计模型的完全充分统计量

22. 假如其中有一个是完全充分统计量而另一个不是. 比如 S 是而 T 不是

由题知 $S = \varphi(T)$, $T = \psi(S)$. 而 S 为充分统计量, 结合 $S = \varphi(T)$ 知 T 也是充分统计量

由于 T 不是完全充分统计量, 所以存在一个 f , 使 $E(f(T)) = 0$ 且 $P(f(T) = 0) \neq 1$

$$\text{而 } 0 = E(f(T)) = E(f(\psi(S))). \text{ 由 } S \text{ 是完全充分统计量知 } P(f(\psi(S)) = 0) = 1$$

即 $P(f(T) = 0) = 1$. 这也就是说, 如果一个是完全充分统计量, 那么另一个也是

23. (1) X_i 的分布密度 $p(x, \lambda) = \begin{cases} \lambda e^{-\lambda x}, & \text{当 } x \geq 0 \text{ 时} \\ 0, & \text{当 } x < 0 \text{ 时} \end{cases}$ 记 $Y = \sum_{i=1}^n X_i$

当 $y \geq 0$ 时, $P(Y \leq y) = \iiint \cdots \int \prod_{i=1}^n p(x_i, \lambda) dx_1 \cdots dx_n$ (积分区域为 $x_1 \geq 0, \dots, x_n \geq 0$
 $0 \leq x_1 + \dots + x_n \leq y$)

$$= \iiint \cdots \int \lambda^n e^{-\lambda(x_1 + \dots + x_n)} dx_1 \cdots dx_n \quad \text{换元: } \begin{cases} S = x_1 + \dots + x_n \\ u_{n-1} = x_{n-1} \\ \vdots \\ u_1 = x_1 \end{cases} \cdot \frac{D(u_1, \dots, S)}{D(x_1, \dots, x_n)} = 1$$

$$= \int_0^y \lambda^n e^{-\lambda s} ds \iiint \cdots \int du_1 \cdots du_{n-1} \quad (\text{后一个积分的区域为 } u_1 \geq 0, \dots, u_{n-1} \geq 0 \\ 0 \leq u_1 + \dots + u_{n-1} \leq s)$$

$$\text{设 } F(n, s) = \iiint \cdots \int du_1 \cdots du_n \quad \begin{pmatrix} u_1 \geq 0, \dots, u_n \geq 0 \\ 0 \leq u_1 + \dots + u_n \leq s \end{pmatrix}$$

$$\text{则 } F(n, s) = \int_0^s F(n-1, s-u_1) du_1 = \int_0^s F(n-1, u_1) du_1$$

$$\text{于是 } \frac{\partial F(n, s)}{\partial s} = F(n-1, s) \quad \frac{\partial^2 F(n, s)}{\partial s^2} = \frac{\partial F(n-1, s)}{\partial s} = F(n-2, s)$$

$$\text{依此类推可得 } \frac{\partial^{n-1} F(n, s)}{\partial s^{n-1}} = F(1, s) = \int_0^s du_1 = s \quad \text{积分 } n-1 \text{ 次得 } F(n, s) = \frac{s^n}{n!}$$

$$\text{因此 } P(Y \leq y) = \int_0^y \lambda^n e^{-\lambda s} \cdot \frac{s^{n-1}}{(n-1)!} ds \quad \text{对 } y \text{ 求导得 } P_Y(y) = \frac{\lambda^n e^{-\lambda y} y^{n-1}}{(n-1)!} \quad (y > 0)$$

$$\text{也就是说 } q(x, \lambda) = I_{[0, +\infty)}(x) \cdot \frac{1}{\Gamma(n)} \lambda^n x^{n-1} \exp\{-\lambda x\}$$

$$(2) \quad E\left(\frac{x_1 + \dots + x_n}{n}\right) = \frac{1}{\lambda} \quad \text{因此一阶矩估计为 } \hat{\lambda} = \frac{1}{\bar{x}_1 + \dots + x_n}$$

$$(3) \quad X_i \text{ 的分布密度为 } p(x, \lambda) = I_{[0, +\infty)}(x) \cdot \lambda \cdot \exp\{-\lambda x\}$$

含内点 + 连续双射 + 线性无关 $\Rightarrow Y = X_1 + \dots + X_n$ 是完全充分统计量

(4) 要构造 $E(Y \text{ 的某个函数}) = \lambda$. 由于 $E(Y) = \frac{n}{\lambda}$ 所以从量级上猜 $\frac{n}{Y}$ 即为所求

$$E\left(\frac{n}{Y}\right) = \int_0^{+\infty} \frac{n}{y} \cdot \frac{1}{(n-1)!} \lambda^n y^{n-1} e^{-\lambda y} dy = \int_0^{+\infty} \frac{n\lambda}{(n-1)!} (\lambda y)^{n-2} e^{-\lambda y} d(\lambda y)$$

$$= \frac{n\lambda}{(n-1)!} \cdot \int_0^{+\infty} y^{n-2} e^{-y} dy = \frac{n\lambda}{(n-1)!} \cdot \Gamma(n-1) = \frac{n}{n-1} \lambda \quad \text{发现差了个系数.}$$

$$\text{因此 } E\left(\frac{n-1}{Y}\right) = \lambda \quad \text{故 } \frac{n-1}{x_1 + \dots + x_n} \text{ 是 } \lambda \text{ 的 UMVU 估计}$$

$$24. \quad E(\zeta^2) = \text{var}(\zeta) + (E(\zeta))^2 = 1$$

$$E(\zeta^4) = 2 \int_0^{+\infty} x^4 \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \stackrel{x=\sqrt{2}t}{=} \sqrt{\frac{2}{\pi}} \int_0^{+\infty} t^{\frac{3}{2}} e^{-t} dt = \sqrt{\frac{2}{\pi}} \Gamma\left(\frac{5}{2}\right) = 3$$

因此 $\text{var}(Z^2) = E(Z^4) - (E(Z^2))^2 = 2$

$$\begin{aligned} 25. (1) E\left(\left(\frac{n-1}{X_1+\dots+X_n} - \lambda\right)^2\right) &= \int_0^{+\infty} \left(\frac{n-1}{y} - \lambda\right)^2 \cdot \frac{1}{(n-1)!} \lambda^n y^{n-1} e^{-\lambda y} dy \\ &= \int_0^{+\infty} \lambda^2 \left(\frac{n-1}{\lambda y} - 1\right)^2 \cdot \frac{1}{(n-1)!} (\lambda y)^{n-1} e^{-\lambda y} d(\lambda y) = \frac{\lambda^2}{(n-1)!} \int_0^{+\infty} \left(\frac{n-1}{y} - 1\right)^2 y^{n-1} e^{-y} dy \\ &= \frac{\lambda^2}{(n-1)!} \left((n-1)^2 \Gamma(n-2) - 2(n-1)\Gamma(n-1) + \Gamma(n) \right) = \frac{\lambda^2}{n-2} \quad (\text{注意, } n=1,2 \text{ 时方差不存在}) \end{aligned}$$

(2) 先提供一个错误做法: 设 $Y = \frac{n-1}{X_1+\dots+X_n}$. 由中心极限定理

$$\frac{Y - E(Y)}{\sqrt{\text{var}(Y)}} \xrightarrow{w} N(0,1) \Rightarrow (Y - E(Y)) \xrightarrow{w} N(0, \frac{\lambda^2}{n-2}) \Rightarrow Y \xrightarrow{w} N(\lambda, \frac{\lambda^2}{n-2})$$

其实从第一步就错了, 中心极限定理说的是, 如果 X_i 独立同分布, 期望、

方差都存在且有限, $Y = \sum_{i=1}^n X_i$. 则 $\frac{Y - E(Y)}{\sqrt{\text{var}(Y)}} \xrightarrow{w} N(0,1)$

以下是正确做法:

由中心极限定理 $\frac{S_n - E(S_n)}{\sqrt{\text{var}(S_n)}} \xrightarrow{w} N(0,1)$. 即 $\sqrt{n}(\bar{X} - \frac{1}{\lambda}) \xrightarrow{w} N(0, \frac{1}{\lambda^2})$

而 $Y = (1 - \frac{1}{n})h(\bar{X})$. 其中 $h(x) = \frac{1}{x}$

由 Δ 方法 $\sqrt{n}(h(\bar{X}) - h(\frac{1}{\lambda})) \xrightarrow{w} N(0, (g'(\frac{1}{\lambda}))^2 \cdot \frac{1}{\lambda^2})$

整理得 $\sqrt{n}(h(\bar{X}) - \lambda) \xrightarrow{w} N(0, \lambda^2)$

由于 Y 与 $h(\bar{X})$ 只差一个 $1 - \frac{1}{n}$ 的倍数, 所以 $\sqrt{n}(Y - \lambda) \xrightarrow{w} N(0, \lambda^2)$

回顾一下 Δ 方法: 设 $Z_1, Z_2, \dots$ 是随机变量序列, 满足 $\sqrt{n}(Z_n - \theta) \xrightarrow{w} N(0, \sigma^2)$

其中 θ 是常数, 又设 $g(x)$ 满足 $g'(\theta) \neq 0$. 则 $\sqrt{n}(g(Z_n) - g(\theta)) \xrightarrow{w} N(0, (g'(\theta))^2 \sigma^2)$

理解: 就是在说如果 Z_n 近似服从正态分布, 那它的函数 $g(Z_n)$ 也近似服从

正态分布. 使用的时候要凑出 $\sqrt{n}(Z_n - \theta)$ 这个式子

26. 我们证明一个更一般的结论: $Z_n \xrightarrow{w} Z, \eta_n \xrightarrow{P} 0$, 则 $Z_n + \eta_n \xrightarrow{w} Z$

证明: 设 x_0 是 Z 的分布函数 $F(x)$ 的连续点, 对 $\varepsilon > 0$, 有

$$P(Z_n + \eta_n \leq x_0) \leq P(\eta_n \leq -\varepsilon) + P(Z_n \leq x_0 + \varepsilon) \leq P(|\eta_n| \geq \varepsilon) + P(Z_n \leq x_0 + \varepsilon)$$

$$\text{于是 } P(Z_n + \eta_n \leq x_0) - F(x_0) \leq P(|\eta_n| \geq \varepsilon) + (P(Z_n \leq x_0 + \varepsilon) - F(x_0 + \varepsilon)) + (F(x_0 + \varepsilon) - F(x_0))$$

任意给定 $\delta > 0$, 取 $\varepsilon_1 > 0$ 足够小, 使得 $F(x_0 + \varepsilon_1) - F(x_0) < \frac{\delta}{3}$ 且 $x_0 + \varepsilon_1$ 是 $F(x)$ 的连续点

由于 $Z_n \xrightarrow{w} Z, \eta_n \xrightarrow{P} 0$, 存在 n_1 使得对一切 $n \geq n_1$ 有
$$\begin{cases} P(Z_n \leq x_0 + \varepsilon_1) - F(x_0 + \varepsilon_1) < \frac{\delta}{3} \\ P(|\eta_n| \geq \varepsilon_1) < \frac{\delta}{3} \end{cases}$$

因此 $n \geq n_1$ 时 $P(Z_n + \eta_n \leq x_0) - F(x_0) < \delta \quad \dots (*)$

$$\text{而 } P(Z_n + \eta_n \leq x_0) \geq P(Z_n \leq x_0 - \varepsilon, \eta_n \leq \varepsilon) \geq P(Z_n \leq x_0 - \varepsilon) - P(\eta_n > \varepsilon) \geq P(Z_n \leq x_0 - \varepsilon) - P(|\eta_n| \geq \varepsilon)$$

$$\text{于是 } P(Z_n + \eta_n \leq x_0) - F(x_0) \geq P(Z_n \leq x_0 - \varepsilon) - F(x_0 - \varepsilon) + F(x_0 - \varepsilon) - F(x_0) - P(|\eta_n| \geq \varepsilon)$$

取 $\varepsilon_2 > 0$, 使 $F(x_0) - F(x_0 - \varepsilon_2) < \frac{\delta}{3}$ 且 $x_0 - \varepsilon_2$ 是 $F(x)$ 的连续点

由于 $Z_n \xrightarrow{w} Z, \eta_n \xrightarrow{P} 0$, 存在 n_2 使得对一切 $n \geq n_2$ 有
$$\begin{cases} P(Z_n \leq x_0 - \varepsilon_2) - F(x_0 - \varepsilon_2) > -\frac{\delta}{3} \\ P(|\eta_n| \geq \varepsilon_2) < \frac{\delta}{3} \end{cases}$$

因此 $n \geq n_2$ 时 $P(Z_n + \eta_n \leq x_0) - F(x_0) > -\delta \quad \dots (**)$

由(*)和(**)知 $n \geq \max\{n_1, n_2\}$ 时有 $|P(Z_n + \eta_n \leq x_0) - F(x_0)| < \delta$

这也就是说 $\lim_{n \rightarrow \infty} P(Z_n + \eta_n \leq x_0) = F(x_0)$, 即 $Z_n + \eta_n \xrightarrow{w} Z$

理解: 证明过程看上去很繁琐, 实际目标是明确的, 就是要证明

$-\delta < P(Z_n + \eta_n \leq x_0) - F(x_0) < \delta$. 而方法也很明确, 就是要将

$P(Z_n + \eta_n \leq x_0) - F(x_0)$ 拆分成我们能调制的几项. 而我们能调制的

东西的形式也很明确, 就是要用 $Z_n \xrightarrow{w} Z, \eta_n \xrightarrow{P} 0$. 按上面这个思路

走应该更容易理解这个证明. 有了这个结论之后, 我们还能证明

若 $Z_n \xrightarrow{w} Z, \eta_n \xrightarrow{P} a$, 则 $Z_n \eta_n \xrightarrow{w} aZ$ (方法就是把 $Z_n \eta_n$ 拆成 $Z_n(\eta_n - a)$ 和 aZ_n 的和)

27. 要证明 $z_n \xrightarrow{P} a (n \rightarrow \infty)$, 也就是 $\lim_{n \rightarrow \infty} P(|z_n - a| \geq \varepsilon) = 0$

也就是 $\lim_{n \rightarrow \infty} P(|\sqrt{n}z_n - a| \geq \sqrt{n}\varepsilon) = 0$

而 $\sqrt{n}(z_n - a) \xrightarrow{d} N(0, \sigma^2)$. 对于给定的 δ , 令 $n \rightarrow \infty$ 则有 $P(|\sqrt{n}(z_n - a)| \geq \sqrt{n}\varepsilon) < \delta$

先来回顾一下 t 分布解决统计问题的方法. 首先是三个重要的结论:

设 $X_1, \dots, X_n \sim \text{iid } N(\mu, \sigma^2)$. 则 (1) $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ (2) $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$ (3) $\bar{X}$ 与 $\sum_{i=1}^n (X_i - \bar{X})^2$ 独立

证明: 设 $\alpha_1 = (\frac{1}{\sqrt{n}}, \dots, \frac{1}{\sqrt{n}})^T$. 把 α_1 扩充为一组标准正交基 $\alpha_1, \alpha_2, \dots, \alpha_n$. 设 $A = \begin{bmatrix} \alpha_1^T \\ \vdots \\ \alpha_n^T \end{bmatrix}$

设 $X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}$. 则 $X \sim N(\mu 1_n, \sigma^2 I_n)$. 于是 $AX \sim N(A(\mu 1_n), \sigma^2 AA^T)$

由于 A 的各行两两正交, 故 $A(\mu 1_n) = \mu \begin{bmatrix} \sqrt{n} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$, $\sigma^2 AA^T = \sigma^2 I_n$

设 $AX = Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}$. 则 $Y \sim N\left(\begin{bmatrix} \sqrt{n}\mu \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma^2 & & \\ & \sigma^2 & \\ & & \ddots \\ & & & \sigma^2 \end{bmatrix}\right)$. 故 $Y_1, \dots, Y_n$ 两两独立

$Y_1 = \frac{1}{\sqrt{n}}(X_1 + \dots + X_n) = \sqrt{n}\bar{X} \sim N(\sqrt{n}\mu, \sigma^2)$. 因此 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

(2) $Y_2, \dots, Y_n \sim \text{iid } N(0, \sigma^2)$. 由 χ^2 分布的定义得 $Y_2^2 + \dots + Y_n^2 \sim \sigma^2 \chi^2(n-1)$

而 $\sum_{i=1}^n Y_i^2 = Y^T Y = (AX)^T (AX) = X^T A^T A X = X^T X = \sum_{i=1}^n X_i^2$

因此 $\sum_{i=2}^n Y_i^2 = \sum_{i=1}^n Y_i^2 - Y_1^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2 = \sum_{i=1}^n (X_i - \bar{X})^2$

(3) 由 $Y_1, \dots, Y_n$ 相互独立, 有 Y_1 与 $Y_2^2 + \dots + Y_n^2$ 独立, 于是 $\bar{X}$ 与 $\sum_{i=1}^n (X_i - \bar{X})^2$ 独立

理解: 矩阵的方法要掌握, χ^2 分布的定义要掌握. 上面的 (1)(2) 两个式子很重要,

下面我们就拿这个 (1)(2) 玩一下.

定义: 设 $z_1, z_2, \dots, z_n \sim \text{iid } N(0, 1)$, 则随机变量 $\frac{z_1}{\sqrt{\frac{1}{n} \sum_{i=2}^n z_i^2}}$ 的分布为自由度为 n 的 t 分布.

它的分布密度为 $f_n(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{\pi n} \Gamma(\frac{n}{2})} \cdot \frac{1}{(1 + \frac{x^2}{n})^{\frac{n+1}{2}}} \quad (x \in \mathbb{R})$

理解: $t(n)$ 分布的分布密度不用记, 但定义要熟悉. 刚刚我们证明了 $\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma} \sim N(0,1)$,

$\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2 \sim \chi^2(n-1)$, $\bar{x}$ 与 $\sum_{i=1}^n (x_i - \bar{x})^2$ 相互独立. 这三句话综合一下, 我们得出:

$T = \frac{\sqrt{n}(\bar{X}-\mu)}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}}$ 的分布是自由度为 $n-1$ 的 t 分布. 这很神奇. σ 在这个式子里被

凭空吃掉了. 而实际应用中我们常常不知道 σ , 而且也不关心它, 所以这个分布很有用.

28. 这题就是刚刚说的, 不知道 σ , 但也不关心 σ , 只关心 μ . 所以适合用 t 分布

取 $T = \frac{\sqrt{n}(\bar{X}-\mu)}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}}$ 作为枢轴量. 记 $t_{1-\alpha}(n-1)$ 为自由度为 $n-1$ 的 t 分布的 $1-\alpha$ 分位数

则 $P(T \leq t_{1-\alpha}(n-1)) = 1-\alpha$.

其实是一件事从不同视角下来看.

上面的式子是从随机变量和概率

的视角. 下面的式子是从统计量和

置信区间的视角

解得 $P(\mu \geq \bar{x} - \frac{1}{\sqrt{n}} t_{1-\alpha}(n-1) \cdot \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}) = 1-\alpha$

代入数据可以算得置信度为 0.95 的置信下限为 10.46

注: 本题样本量较小, 所以需用 t 分布来解. 如果样本量较大, 也可以用如下方法:

中心极限定理给出 $\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma} \xrightarrow{w} N(0,1)$. 用样本方差代替 σ , 用正态分布分位数给出置信区间

29. 和上题一样. 小样本, σ 未知, 要求 μ 的置信区间

取 $T = \frac{\sqrt{n}(\bar{X}-\mu)}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}}$ 作为枢轴量. 则 $P(|T| \leq t_{1-\frac{\alpha}{2}}(n-1)) = 1-\alpha$

解得 $P(\bar{x} - \frac{1}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1) \cdot \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \leq \mu \leq \bar{x} + \frac{1}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1) \cdot \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}) = 1-\alpha$

代入数据算得置信度为 0.95 的置信区间为 [263.84, 289.95]

30. 要证 $\varphi^2(x_0 - \mu) < \left(\int_{x_0 - \mu}^{+\infty} \varphi(t) dt \right) \left(1 - \int_{x_0 - \mu}^{+\infty} \varphi(t) dt \right)$

记 $F(x_0, \mu) = \varphi^2(x_0 - \mu) - \int_{x_0 - \mu}^{+\infty} \varphi(t) dt + \left(\int_{x_0 - \mu}^{+\infty} \varphi(t) dt \right)^2$

则 $\frac{\partial F}{\partial x_0} = 2\varphi(x_0 - \mu) - \varphi(x_0 - \mu) + 2\varphi(x_0 - \mu) \int_{x_0 - \mu}^{+\infty} \varphi(t) dt = \varphi(x_0 - \mu) \left(1 + 2 \int_{x_0 - \mu}^{+\infty} \varphi(t) dt \right) > 0$

因此 F 随 λ 增大而增大. 于是 $F(\lambda_0, \mu) < F(+\infty, \mu) = 0$

31. 设 $B = (b_{ij})_{n \times n}$. 考虑
$$\begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nn} \end{bmatrix} \begin{bmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} & \cdots & \frac{\partial x_2}{\partial y_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \frac{\partial x_n}{\partial y_2} & \cdots & \frac{\partial x_n}{\partial y_n} \end{bmatrix}$$

两矩阵乘积的第 (i, j) 位置为 $\sum_{k=1}^n b_{ik} \cdot \frac{\partial x_k}{\partial y_j} = \frac{\partial (\sum_{k=1}^n b_{ik} x_k)}{\partial y_j} = \frac{\partial (y_i - \mu_i)}{\partial y_j}$

因此 $\begin{bmatrix} b_{11} & \cdots & b_{1n} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{nn} \end{bmatrix} \begin{bmatrix} \frac{\partial x_1}{\partial y_1} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \cdots & \frac{\partial x_n}{\partial y_n} \end{bmatrix} = I_n$. 故 $\begin{bmatrix} \frac{\partial x_1}{\partial y_1} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \cdots & \frac{\partial x_n}{\partial y_n} \end{bmatrix} = B^{-1}$

32. (1) 现在 $X_1, \dots, X_n \sim \text{iid } N(0, 1)$. 要求 $Y = X_1^2 + \dots + X_n^2$ 的分布密度

对 $y \geq 0$. 有 $P(Y \leq y) = \iiint \left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{1}{2}(x_1^2 + \dots + x_n^2)} dx_1 \cdots dx_n$ (积分区域为 $x_1^2 + \dots + x_n^2 \leq y$)

$= \int_{r=0}^{\sqrt{y}} \int_{\Omega} \left(\frac{1}{\sqrt{2\pi}}\right)^n e^{-\frac{r^2}{2}} r^{n-1} dr d\Omega = \left(\frac{1}{\sqrt{2\pi}}\right)^n \left(\int_{\Omega} d\Omega\right) \int_0^{\sqrt{y}} r^{n-1} e^{-\frac{r^2}{2}} dr$

而 $\int_{\Omega} 1 \cdot d\Omega = \text{单位球面面积} = \frac{2\pi^{\frac{n}{2}}}{\Gamma(\frac{n}{2})}$. 则 $P(Y \leq y) = \frac{2^{1-\frac{n}{2}}}{\Gamma(\frac{n}{2})} \int_0^{\sqrt{y}} r^{n-1} e^{-\frac{r^2}{2}} dr$

两边对 Y 求导得 $P_Y(y) = \frac{2^{1-\frac{n}{2}}}{\Gamma(\frac{n}{2})} \cdot \frac{1}{2\sqrt{y}} \cdot y^{\frac{n-1}{2}} e^{-\frac{y}{2}} = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} y^{\frac{n}{2}-1} e^{-\frac{y}{2}}$

(2) 在第10题解答中已给出详细过程

33. (1) 同29题. 取 $T = \frac{\sqrt{n}(\bar{X} - \mu)}{\sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}}$ 作为枢轴量. 则 $P(|T| \leq t_{1-\frac{\alpha}{2}}(n-1)) = 1 - \alpha$

解得 $P\left(\bar{X} - \frac{1}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1) \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \leq \mu \leq \bar{X} + \frac{1}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1) \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}\right) = 1 - \alpha$

代入数据算得 μ 的置信度为 0.95 的置信区间为 $[154.78, 155.48]$

(2) 小样本, μ 与 σ 都未知, 不关心 μ . 要求 σ 的置信上限方法是 $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$

由 $P\left(\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \geq \chi_{\alpha}^2(n-1)\right) = 1 - \alpha$ 解得 $P\left(\sigma \leq \sqrt{\frac{1}{\chi_{\alpha}^2(n-1)} \sum_{i=1}^n (X_i - \bar{X})^2}\right) = 1 - \alpha$

代入数据算得 σ 的置信度为 0.95 的置信上限为 0.806

$$34. (1) A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, Y = AX = \begin{bmatrix} X_1 + X_2 \\ X_1 - X_2 \end{bmatrix}$$

$$\text{则 } \mu_Y = A\mu_X = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} \mu \\ \mu \end{bmatrix} = \begin{bmatrix} 2\mu \\ 0 \end{bmatrix}$$

$$M_Y = AM_X A^T = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} \sigma^2 & 0 \\ 0 & \sigma^2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 2\sigma^2 & 0 \\ 0 & 2\sigma^2 \end{bmatrix}$$

故 $X_1 + X_2$ 与 $X_1 - X_2$ 服从二维正态分布 $N\left(\begin{pmatrix} 2\mu \\ 0 \end{pmatrix}, \begin{bmatrix} 2\sigma^2 & 0 \\ 0 & 2\sigma^2 \end{bmatrix}\right)$

(隐含用到定理: X_1 与 X_2 独立且都是正态分布, 则 $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ 服从二元正态分布. 二元正态分布的线性组合仍是二元正态分布)

(2) 协方差矩阵是对角矩阵 $\Rightarrow 0 = \rho\sigma_1\sigma_2 \Rightarrow \rho = 0$

$$\text{在 } f(y_1, y_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)}\left(\frac{(y_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(y_1-\mu_1)(y_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(y_2-\mu_2)^2}{\sigma_2^2}\right)\right\}$$

$$\begin{aligned} \text{中代入 } \rho=0 \text{ 得 } f(y_1, y_2) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left\{-\frac{1}{2}\left(\frac{(y_1-\mu_1)^2}{\sigma_1^2} + \frac{(y_2-\mu_2)^2}{\sigma_2^2}\right)\right\} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(y_1-\mu_1)^2}{2\sigma_1^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y_2-\mu_2)^2}{2\sigma_2^2}} \end{aligned}$$

因此 Y_1 与 Y_2 独立. 即 $X_1 + X_2$ 与 $X_1 - X_2$ 独立

35. (1) 有如下结论: $X \sim N(\mu, M)$. A 行满秩, $Y = AX \Rightarrow Y \sim N(A\mu, AMA^T)$

$$\begin{aligned} \text{证明: } \text{cov}(Y_i, Y_j) &= \text{cov}(A_i X, A_j X) = \text{cov}\left(\sum_{k=1}^n a_{ik} X_k, \sum_{k=1}^n a_{jk} X_k\right) \\ &= E\left(\left(\sum_{k=1}^n a_{ik}(X_k - E(X_k))\right)\left(\sum_{l=1}^n a_{jl}(X_l - E(X_l))\right)\right) \\ &= \sum_{k=1}^n \sum_{l=1}^n a_{ik} a_{jl} E\left((X_k - E(X_k))(X_l - E(X_l))\right) \end{aligned}$$

$$\begin{aligned} (AMA^T)(i; j) &= \sum_{k=1}^n A(i; k) (MA^T)(k; j) = \sum_{k=1}^n a_{ik} \left(\sum_{l=1}^n M(k; l) A^T(l; j)\right) \\ &= \sum_{k=1}^n a_{ik} \left(\sum_{l=1}^n E((X_k - E(X_k))(X_l - E(X_l))) a_{jl}\right) \end{aligned}$$

因此 $A^T X \sim N(A^T \cdot 1\mu, \sigma^2 A^T A)$

$$\Rightarrow A^T X \text{ 的分布密度为 } f_{A^T X}(y) = \frac{1}{(2\pi)^{\frac{k}{2}} |\sigma^2 A^T A|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(y - \mu A^T 1)^T (\sigma^2 A^T A)^{-1} (y - \mu A^T 1)\right]$$

$$(2) \text{ 令 } C = \begin{bmatrix} A^T \\ B^T \end{bmatrix}, Y = CX = \begin{bmatrix} A^T X \\ B^T X \end{bmatrix}$$

则由 $X \sim N(\mu 1_n, \sigma^2 I_n)$ 知 $Y \sim N(\mu C \cdot 1_n, \sigma^2 CC^T)$

$$\text{而 } CC^T = \begin{bmatrix} A^T \\ B^T \end{bmatrix} [A \ B] = \begin{bmatrix} A^T A & A^T B \\ B^T A & B^T B \end{bmatrix} = \begin{bmatrix} A^T A & 0 \\ 0 & B^T B \end{bmatrix}$$

因此 $A^T X$ 与 $B^T X$ 的 ρ 为 0, 进而 $A^T X$ 与 $B^T X$ 独立

$$36. \text{ 令 } B = \begin{bmatrix} 1 & 0 \\ -b & 1 \end{bmatrix}, Y = BX = \begin{bmatrix} X_1 \\ X_2 - bX_1 \end{bmatrix} \triangleq \begin{bmatrix} Y_1 \\ Y_2 \end{bmatrix}$$

这个是第一行第二列
的元素的意思

则 $Y \sim N(B\mu, BMB^T)$. 而 X_1 与 $X_2 - bX_1$ 独立等价于 $BMB^T(1;2) = 0$

$$BMB^T = \begin{bmatrix} 1 & 0 \\ -b & 1 \end{bmatrix} \begin{bmatrix} m_{11} & m_{12} \\ m_{21} & m_{22} \end{bmatrix} \begin{bmatrix} 1 & -b \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -b & 1 \end{bmatrix} \begin{bmatrix} m_{11} & m_{12} - bm_{11} \\ m_{21} & m_{22} - bm_{21} \end{bmatrix} = \begin{bmatrix} m_{11} & m_{12} - bm_{11} \\ m_{21} - bm_{11} & -bm_{12} + b^2 m_{11} + m_{22} - bm_{21} \end{bmatrix}$$

因此 $m_{12} - bm_{11} = 0$. 即 $b = \frac{m_{12}}{m_{11}} = \frac{\text{COV}(X_1, X_2)}{\text{COV}(X_1, X_1)}$

$$37. Y = AX + d \sim N(A\mu + d, AI_3 A^T)$$

$$A\mu + d = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix} + \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \end{bmatrix} \quad AA^T = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 5 & 1 \\ 1 & 2 \end{bmatrix}$$

$$38. p_X(x) = \left(\frac{1}{\sqrt{2\pi}}\right)^n |M|^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}(x-\mu)^T M^{-1}(x-\mu)\right\}$$

先证 $E(X) = \mu$:

由于 M 对称正定, 于是存在矩阵 $M^{\frac{1}{2}}$, 使 $(M^{\frac{1}{2}})^2 = M$

作变量替换 $Y = M^{-\frac{1}{2}}(X - \mu)$. 即 $X = \mu + M^{\frac{1}{2}}Y$

则 $p_Y(y) = \left(\frac{1}{\sqrt{2\pi}}\right)^n |M|^{-\frac{1}{2}} \exp\left\{-\frac{1}{2}y^T y\right\} \cdot |M^{\frac{1}{2}}|$ 这个是雅克比行列式

即 $p_Y(y) = \frac{1}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}y^T y}$. 这正是 n 维标准正态分布 $N(0, I_n)$

因此 $E(X) = \mu + M^{\frac{1}{2}}E(Y) = \mu$

再证 $\text{cov}(X, X) = M$:

$$\begin{aligned} \text{同上, 令 } X &= \mu + M^{\frac{1}{2}}Y. \text{ 则 } \text{cov}(X, X) = E[(X - \mu)(X - \mu)^T] \\ &= E[(M^{\frac{1}{2}}Y)(M^{\frac{1}{2}}Y)^T] = M^{\frac{1}{2}}E(YY^T)M^{\frac{1}{2}} = M^{\frac{1}{2}} \cdot I_n \cdot M^{\frac{1}{2}} = M \end{aligned}$$

$$39. G(k, p) = \sum_{i=k}^n C_n^i p^i (1-p)^{n-i}. \text{ 要证 } G(k, p) = \frac{n!}{(k-1)!(n-k)!} \int_0^p x^{k-1}(1-x)^{n-k} dx$$

$$\begin{aligned} \text{由 } \frac{\partial G}{\partial p} &= \sum_{i=k}^n C_n^i [i p^{i-1} (1-p)^{n-i} - (n-i)(1-p)^{n-i-1} p] \\ &= \sum_{i=k}^n C_n^i p^{i-1} (1-p)^{n-i-1} (i(1-p) - (n-i)p) \\ &= \sum_{i=k}^n \left[\frac{n!}{i!(n-i)!} p^{i-1} (1-p)^{n-i-1} \cdot i(1-p) - \frac{n!}{i!(n-i)!} p^{i-1} (1-p)^{n-i-1} (n-i)p \right] \\ &= \sum_{i=k}^n (nC_{n-1}^{i-1} p^{i-1} (1-p)^{n-i} - nC_{n-1}^i p^i (1-p)^{n-i-1}) \\ &= (nC_{n-1}^{k-1} p^{k-1} (1-p)^{n-k} - nC_{n-1}^k p^k (1-p)^{n-k-1}) \\ &\quad + (nC_{n-1}^k p^k (1-p)^{n-k-1} - nC_{n-1}^{k+1} p^{k+1} (1-p)^{n-k-2}) \end{aligned}$$

$$+ \dots + \left(n C_{n-1}^{n-1} p^{n-1} (1-p)^0 - n C_{n-1}^n p^n (1-p)^{n-n-1} \right)$$

$$= n C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k} \quad (\text{相邻的项消掉了})$$

$$\Rightarrow G(k, p) = \int_0^p n C_{n-1}^{k-1} p^{k-1} (1-p)^{n-k} dp + G(k, 0)$$

$$= \frac{n!}{(k-1)!(n-k)!} \int_0^p x^{k-1} (1-x)^{n-k} dx$$

40. 治疗前样本均值 $\bar{x}_1 = 104.5$, 标准差 $S_1 = 21.454$

治疗后样本均值 $\bar{x}_2 = 96.5$, 标准差 $S_2 = 12.425$

独立双样本, 方差相等时, 合并方差 $S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}$

置信区间公式为 $\left[(\bar{x}_1 - \bar{x}_2) - t_{\frac{\alpha}{2}, n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, (\bar{x}_1 - \bar{x}_2) + t_{\frac{\alpha}{2}, n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right]$

代入算得答案为 $(-1.06, 17.06)$